



南京理工大学
NANJING UNIVERSITY OF SCIENCE & TECHNOLOGY

毕业设计说明书

姓 名 艾力西尔·买买提艾力

学 号 920106840646

学 院 计算机科学与工程学院

专业（方向） 软件工程

班 级 9201065501

题 目 基于图对比学习的深度推荐方
法研究

指 导 教 师 孟顺梅 副教授

2024 年 5 月

声 明

我声明，本毕业设计说明书及其研究工作和所取得的成果是本人在导师的指导下独立完成的。研究过程中利用的所有资料均已在参考文献中列出，其他人员或机构对本毕业设计工作做出的贡献也已在致谢部分说明。

本毕业设计说明书不涉及任何秘密，南京理工大学有权保存其电子和纸质文档，可以借阅或网上公布其部分或全部内容，可以向有关部门或机构送交并授权保存、借阅或网上公布其部分或全部内容。

学生签名：

日期：

指导教师签名：

日期：

毕业设计说明书中文摘要

在信息爆炸的今天，推荐系统应运而生，以解决信息过载的难题。然而传统的推荐方法存在着数据稀释、冷启动等问题。对比学习技术在各种图任务上表现出了优越的性能，基于对比学习的嵌入学习逐渐成为推荐领域中一种被广泛探索的新兴推荐模式。传统的图卷积网络模型存在一些局限性，包括稀疏的监督信号、数据分布的倾斜和交互中的噪音。为了解决这些问题，本文将图卷积技术和对比学习相结合，提出一种基于图对比学习的深度推荐方法。该方法通过生成节点的多个视图，并最大化同一节点在不同视图间的一致性，从而增强对交互噪音的鲁棒性提升推荐准确度。实证研究表明，该方法在三个基准数据集上取得了良好的效果，在提升推荐准确性的同时增强了推荐系统的鲁棒性。

关键词 协同过滤 推荐系统 图神经网络 对比学习

毕业设计说明书外文摘要

Title Research on Deep Recommendation Methods

Based on Graph Contrastive Learning

Abstract

In today's era of information explosion, recommendation systems have emerged to solve the problem of information overload. However, traditional recommendation methods have problems such as data dilution and cold start. Contrastive learning technology has shown superior performance on various graph tasks, and embedding learning based on contrastive learning has gradually become an emerging recommendation model that has been widely explored in the recommendation field. Traditional graph convolutional network models suffer from several limitations, including sparse supervision signals, skewed data distribution, and noise in interactions. In order to solve these problems, this paper combines graph convolution technology and contrastive learning to propose a deep recommendation method based on graph contrastive learning. This method generates multiple views of a node and maximizes the consistency of the same node between different views, thereby enhancing the robustness to interaction noise and improving recommendation accuracy. Empirical studies show that this method achieves good results on three benchmark data sets, improving recommendation accuracy while enhancing the robustness of the recommendation system.

Keywords Collaborative Filtering Recommender System Graph Neural Networks Contrastive Learning

目 录

1 引言	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 推荐系统的历史发展	2
1.2.2 基于图神经网络的推荐系统	3
1.3 总体技术方案	4
1.4 技术方案的经济因素分析	5
1.5 章节安排	5
2 相关技术与理论	6
2.1 协同过滤推荐算法	6
2.1.1 基于邻域的协同过滤算法	6
2.1.2 基于模型的协同过滤算法	7
2.2 图表示学习	8
2.3 图神经网络	10
2.4 图对比学习	10
3. 基于图对比学习的深度推荐方法	12
3.1 问题描述	12
3.2 整体框架	12
3.2.1 基于图神经网络的节点表征学习	14
3.2.2 基于图结构的数据增强	15
3.2.3 基于增强视图的图对比学习	15
3.2.4 基于图对比学习的多任务训练	16
3.3 算法描述	16
4. 实验与分析	18
4.1 实验环境	18
4.2 数据集	18
4.3 评估指标介绍	18
4.4 实验参数设置	19
4.5 准确性分析	19
4.6 超参数分析	20
4.6.1 不同网络层数的影响	20
4.6.2 不同温度参数的影响	21
4.6.3 不同丢弃率的影响	22
4.6.4 不同 λ 权重系数的影响	23
结论	25
致谢	26
参考文献	27

1 引言

本文研究的课题内容是基于图对比学习的深度推荐方法研究。首先通过对用户和项目的二分图进行数据增强，来产生多种视图，然后通过图编码的方式形成不同视图下的节点表征，并在这些视图表征上做对比学习。因此为解决传统的图卷积网络(Graph Convolutional Network, GCN)模型中的稀疏的监督信号、数据分布的倾斜和交互中的噪音等问题，本文通过生成节点的多个视图提供辅助的监督信号来降低度量偏差，并最大化同一节点不同视图之间的一致性。以此来改进基于用户-项目二分图表征学习的推荐系统的长尾问题和鲁棒性问题。

1.1 研究背景及意义

随着互联网向人们生活的渗透，从新闻、社交媒体、电子商务，到网络论坛、博客……每天都会涌现出大量的信息，信息过载问题也随之产生。信息过载增加了人们的选择困难。在过去信息的获取相对有限，人们的选择范围也相对较小。但现在面对着数量庞大的选项和观点，我们很难确定最适合自己的选择。这种选择困难不仅出现在购物决策中，也涉及到其他领域如旅行、娱乐、学习等。人们可能会花费大量时间和精力来寻找最佳选项，同时也可能因为担心错过更好的选择而感到焦虑和不安。

信息检索推荐系统有效的为我们缓解了信息过载的问题。信息检索是人们获取信息的主要途径，因此其功能的准确性、效率和用户体验至关重要。信息检索需要具备良好的索引和检索算法，确保针对用户的查询请求能够快速精准地返回相应结果，从而协助用户定位并获取所需信息。并且推荐系统更加注重根据用户的兴趣、偏好和行为，通过个性化推荐算法和模型，主动将个性化内容推荐给用户，帮助用户从海量信息中找到用户感兴趣的信息^[1]。不仅可以减少用户的选择困难，满意度和参与度也会得到很好的提升。

协同过滤是推荐系统中使用较为广泛的算法。它基于一个简单的假设：如果一群用户的行为和偏好在某些方面更加相似，那么他们的兴趣爱好在其他方面可能也会更加接近。协同过滤算法首先通过构建相似度矩阵来量化用户之间或物品之间的相似程度。基于这些相似度评分，算法能够有效地执行个性化推荐，为用户提供与其偏好高度契合的内容或物品。通过不断迭代和优化，协同过滤算法可以提供个性化、准确的推荐结果，帮助用户发现新的兴趣和内容^[2]。

尽管协同过滤算法在推荐系统中扮演着重要角色，但它仍面临一系列待解的挑战，如数据稀疏性、冷启动、以及在大规模数据集下的可扩展性。为了进一步提升推荐的质量和效果，需要考虑将协同过滤与其他先进的推荐算法和技术相结合以实现更高质量的推荐效果。为解决传统推荐系统中初始数据不足的问题，研究人员们将辅助信息引入推荐算法中^[3]。这些辅助信息可以包括社交网络关系、用户或物品的详细信息、图片内容以及知识图谱等。通过利用这些辅助信息，可以提供更全面的特征和上下文信息，从而改善推荐预测的准确性和个性化程度^[4]。因此基于这些不同类型的辅助信息，如今发展了基于社交网络、基于用户/物品信息、基于图片、基于内容以及基于知识图谱等不同的推荐算法。其中基于图对比学习的深度推荐方法随着近几年图神经网络和对比学习的兴起成为了研究的热点。图对比学习方法能够利用图结构来建模用户和物品之间的关联性，通过学习图表征和对比学习来提高推荐的准确性和个性化程度。

1.2 国内外研究现状

1.2.1 推荐系统的历史发展

推荐系统的本质其实就是先获取用户的历史信息，包括行为、偏好等，再根据用户的兴趣为其提供相应的个性化推荐服务的系统。推荐系统的核心目标在于从庞大而繁杂的物品、产品、服务及信息库中，筛选出与用户兴趣和需求最为契合、价值最高的内容。为实现这一目标，传统的推荐算法通常可以划分为三大类别：基于内容的推荐算法、基于协同过滤的推荐算法以及融合了前两者特点的混合推荐算法。这些算法致力于为用户提供精准且个性化的内容推荐。

传统推荐系统的历史悠久，早在1992年Belkin和Croft^[5]对信息过滤和信息检索进行了分析比较，其中信息检索是搜索引擎的基础技术，而推荐系统主要基于信息过滤技术。同年，Goldberg等人^[6]提出了Tapestry系统，这是第一个基于人工评价协同过滤的信息过滤系统。受到这项研究的启发，麻省理工学院(MIT)和明尼苏达大学(UMN)的一些研究人员开发了这项网络新闻推荐服务，命名为GroupLens^[7]，其关键组件是用户-用户协同过滤模型。直到1997年Resnick^[8]等人提出推荐系统的概念，使得这一领域成为了研究的热点。Linden^[9]等人在2003年的研究中提出了一种基于项目的协同过滤算法。研究人员需要在Netflix于2006年10月发布的近1亿个匿名电影评分数据集上建立一个系统，以便在准确性方面超越Netflix自己的推荐系统Cinematch。许多研究人员都参加了这项比赛，

这极大地促进了推荐系统的发展，并加深了企业界和学术界对推荐系统的了解。首届ACM推荐系统会议由明尼苏达大学教授Joseph A Konstan于2007年举办。迄今为止，这一推荐系统领域的顶级会议已举办了七届。每年都吸引了来自各个学科领域的研究者参加。此时推荐系统的研究热浪涌起，发展迎来了历史新高。同时也随着互联网的飞速发展，信息不断爆炸喷涌，传统的推荐系统在解决数据稀疏和冷启动问题上逐渐显得乏力。为了解决这些问题，Gori^[10]等人在2008年发布的文章中提出数据之间的许多潜在关系都可以用图表来表示，而他们提出的这种新的神经网络模型称之为图神经网络(Graph Neural Networks,GNN)模型。该方法对现有的神经网络方法进行了扩展，旨在有效应对并处理图领域中呈现的数据。图神经网络的引入使得推荐系统可以考虑更丰富的关系信息、其模型结构灵活，可以处理异构数据并且可以结合上下文信息进行推荐。

1.2.2 基于图神经网络的推荐系统

在数字时代，信息的爆炸式增长已经成为我们面临的挑战之一。为了应对这一挑战，推荐系统作为一种有效的信息过滤工具，受到了广泛关注。与此同时，图结构数据及其处理技术——特别是图神经网络^[11]，也在这一背景下崭露头角^{[12][13]}。图神经网络，这一概念的提出可追溯到2005年，为处理图结构数据提供了强大的工具。它借鉴了传统卷积神经网络^[14]的思想，通过图卷积等方法，从节点的邻域中提取局部结构信息，进而完成诸如链接预测和节点分类等任务。在推荐系统领域，研究人员发现，用户与产品之间的交互数据天然地呈现出图结构的特点。例如，用户的点击或购买行为可以表示为用户与项目之间的链接。这种图结构数据为推荐系统提供了丰富的关系信息，有助于更深入地理解用户行为。基于图的学习方法被广泛应用于推荐系统中，形成了基于图的推荐系统。这些系统首先构建图数据，将用户、内容和项目作为不同类型的节点，并将它们之间的联系（如朋友关系、视频观看、互动或购买）表示为边。此外，用户、内容和物品的属性也被作为节点属性添加到图数据中，而边则可以包含时间戳、购买数量等属性。通过图神经网络，这些基于图的推荐系统能够迭代地聚合相邻节点的特征，更新目标节点的特征。这种传播机制使得系统能够充分利用用户-物品互动中固有的丰富关系信息，从而改进推荐效果并加深对用户行为的理

解。总之，随着信息数据的不断增长，图神经网络在推荐系统中的应用将越来越广泛。通过构建图数据并利用图神经网络进行学习和推理，我们能够更好地应对信息过载问题，为用户提供更加精准和个性化的推荐服务。

在图神经网络架构中，注意力机制的核心在于通过专门的注意力模块替代传统图卷积神经网络中的卷积激活功能，从而赋予网络更强的焦点感知能力。为了优化注意力机制的表现，多种方法倾向于整合门控信息，以此动态调整对特定感受域的注意力权重参数，进而提升其在实际推理和应用中的效率。与侧重于节点分类的传统图卷积神经网络不同，注意力机制在自然语言处理等领域已展现出出色性能。尤其是图注意力网络（Graph Attention Network, GAT），在处理邻居节点特征时，摒弃了简单的累加求和方式，而是采用全局注意力机制。这种机制摒弃了固定的卷积分层传递模式，使其能够更灵活地依据图结构的特性，对关键节点、子图、模型或路径分配更高的注意力权重。Zhang 及其团队^[15]在流量速度预测领域引入了一种创新的自我注意力机制，该机制通过卷积子网络动态调整权重，并辅以循环门控单元以提升预测准确性。与此同时，Lee 的研究小组^[16]开发了一种基于 LSTM 的融合模型，巧妙地将注意力机制用于图节点分类任务中，以提升分类的精准度。而 Abu El Haija 的研究者们^[17]则提出了注意力游走技术，这一方法将图注意力机制有效应用于节点嵌入过程中。在现实世界的数据表示中，信息往往以节点和边构成的拓扑结构形式呈现，这种特殊的数据结构被称为异构信息网络。在这一背景下，Xiao 等研究人员^[18]开发了一种独特的异构图注意力网络，它依赖于节点层的注意力机制来判断同属性邻节点的重要性，进而揭示节点与边之间的异构性。不仅如此，图注意力网络的研究领域已进一步拓展至图像语义分析、上下文关系挖掘等多个重要维度，展示了其在处理复杂信息关联方面的广泛适用性。例如，Wang 等学者^[19]在解决自然语言描述图像的问题时，提出了一种创新方法。该方法首先通过深入分析图像间的语义关联，构建出具有逻辑结构的关联图。接着，利用动态图注意力网络机制，对图像中的语义信息进行精确推理和解析，从而实现了对图像内容的更深入理解。

1.3 总体技术方案

本课题要解决的问题是基于图对比学习的深度推荐方法研究。首先从数据集中获取用户和项目的特征信息，将这些特征信息映射为二分图形式，并对图

中的节点和边实施数据增强。通过这一步骤，我们得到的增强视图可视为原始图的一个子结构。在这个子结构上，我们可以采用诸如LightGCN等图卷积神经网络模型来进一步提取节点的表征信息，这样会产生一个节点的多种不同表征，然后结合对比学习构造图对比学习任务。之后在ml-1M、douban-book、Yelp-2018三个数据集上与LightGCN结果进行比对，具体比较Recall和NDCG两个值。之后再对图对比学习推荐方法进行超参数分析，探究不同参数的变化对系统推荐结果的影响。

1.4 技术方案的经济因素分析

本课题充分考虑了技术方案的经济可行性，选取了合适的数据集便于普通的个人电脑训练模型，无需额外购买专业显卡或租用服务器，经济负担小，可行性高。

1.5 章节安排

本文主要分为五个章节，详细安排如下所示：

第一章，引言部分，简要介绍了课题的研究背景及其意义，详细描述了国内外研究现状和重点，并介绍了本课题的总体技术方案与方案的可行性。

第二章，理论部分，介绍了协同过滤算法、图表示学习、图神经网络和图对比学习。

第三章，模型部分，阐述了方法的总体流程，具体为基于图神经网络的节点表征学习、基于图结构的数据增强、基于增强视图的图对比学习和基于图对比学习的多任务训练。

第四章，实验部分，将模型应用于ml-1M、douban-book、Yelp-2018三个数据集，并探究了模型各参数对推荐性能的影响程度，与LightGCN进行对比分析，验证了模型的有效性。

2 相关技术与理论

本文将详细阐明传统推荐系统和图对比学习相关的基础理论知识。

2.1 协同过滤推荐算法

在传统的个性化推荐系统中，协同过滤算法是推荐的基础架构，其原理在于，通过分析用户的历史行为数据，识别出其他与当前用户兴趣相似的用户或商品，进而预测并推荐可能吸引当前用户的商品。协同过滤的计算方法主要可划分为两大类别：一类是基于邻域的方法，通过计算用户或商品之间的相似度来推荐；另一类则是基于模型的方法，通过建立用户行为模型来实现精准推荐。图2.1展示了的具体分类情况，下面详细介绍两种方式。

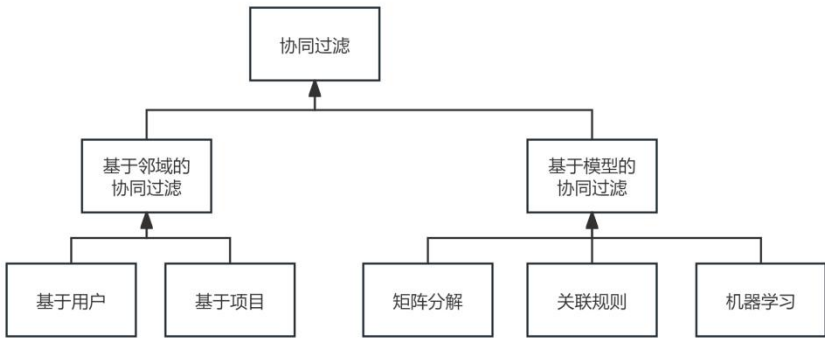


图2.1 协同过滤算法分类图

2.1.1 基于邻域的协同过滤算法

基于邻域的协同过滤算法主要可分为基于用户的协同过滤算法和基于项目的协同过滤算法两种。

(1) 基于用户的协同过滤算法

基于用户的协同过滤算法旨在通过识别与当前用户具有相似行为模式和偏好的其他用户，来预测并推荐当前用户可能感兴趣的物品。该算法的工作流程如下：首先，算法会收集用户的偏好数据，这些数据既包含用户主动给出的显式反馈，如评分和评论，也包含通过用户行为推断出的隐式反馈，如点击、浏览时长、收藏以及购买记录等。接着，算法会基于这些偏好数据，运用各种相似度计算方法，如Jaccard相似度或余弦相似度等，来识别出与当前用户最为相似的其他用户群体。最后，基于这些相似用户的喜好和偏好，算法会为当前用

户推荐那些相似用户所喜爱的物品，从而实现个性化的推荐服务。这一过程充分利用了用户之间的相似性，提高了推荐的准确性和有效性。

这种算法的优势在于可以利用用户的历史行为数据，为用户提供个性化的推荐。设 $N(u)$ 为用户 u 有过正反馈的项目合集， $N(v)$ 为用户 v 有过正反馈的项目合集。则 u 和 v 的兴趣相似度有以下两种计算方式：

$$1)\text{Jaccard相似度:} \quad \omega_{uv} = \frac{|N(u) \cap N(v)|}{|N(u) \cup N(v)|} \quad (2-1)$$

$$2)\text{余弦相似度:} \quad \omega_{uv} = \frac{|N(u) \cap N(v)|}{\sqrt{|N(u)| |N(v)|}} \quad (2-2)$$

$$p(u, i) = \sum_{v \in S(u, K)} \omega_{uv} * r_{vi} \quad (2-3)$$

兴趣度预测需要计算用户 u 对邻域用户购买过项目 i 的感兴趣程度 $p(u, i)$ ，对邻域用户的兴趣度加权求和如式(2-3)，该公式中 $S(u, K)$ 表示和用户 u 最相似的 K 个用户， ω_{uv} 表示用户 u 和用户 v 的兴趣相似度， r_{vi} 表示观测到的用户 v 对项目 i 的兴趣度，通过该相似度生成推荐列表。

(2) 基于项目的协同过滤算法

基于项目的协同过滤算法的思路是：根据用户对已有项目的反馈，寻找与这些项目相似的其他项目并推荐给用户。该算法以用户对项目的偏好为基础，通过识别与用户已喜欢项目相似的其他项目来进行推荐。与基于用户的协同过滤算法相类似，基于项目的推荐算法同样需要进行项目之间的相似度计算，以便准确推荐与用户兴趣相契合的内容：

$$\omega_{ij} = P(j|i) = \frac{|N(i) \cap N(j)|}{|N(i)|} \quad (2-4)$$

在公式(2-4)中， $N(i) \cap N(j)$ 表示同时点击过项目 i 和项目 j 的用户集。用 $p(u, i)$ 表示用户 u 对候选项目 i 的感兴趣程度，再对已反馈的项目的兴趣度加权求和：

$$p(u, i) = \sum_{j \in N(u)} I(i \in S(i, K)) * \omega_{ij} * r_{uj} \quad (2-5)$$

在公式(2-5)中， $S(i, K)$ 表示和项目 i 最相似的 K 个项目。 $N(u)$ 表示用户 u 有过正反馈的项目集合。 ω_{ij} 表示项目 i 和项目 j 的相似度。 r_{uj} 表示观测到的用户 u 对项目 j 的兴趣度，继而通过 $p(u, i)$ 生成推荐列表。

2.1.2 基于模型的协同过滤算法

基于模型的协同过滤算法的基本思路是：通过建立模型从而对用户某一

项目的偏好程度进行预测。该算法建立在用户兴趣与相似用户或类似项目之间具有关联性的假设之上，它通过挖掘历史用户-项目交互数据来揭示这种关联性，并据此构建预测模型。基于这一模型，算法能够执行精准的预测和推荐。具体而言，基于模型的协同过滤算法通常遵循以下关键步骤：先收集用户的历史评分或偏好项目的资料；然后以余弦相似度、欧氏距离等用户或项目之间的相似度量作为依据，计算用户或物品之间的相似度；其次是利用历史的用户-项目交互数据和相似度信息训练一个预测模型，例如矩阵分解、基于邻域的方法等基于统计的方法；最后根据所学习到的模型，对没有得到用户评分的项目进行预测，并将用户可能感兴趣的项目推荐给他们。

介于基于模型的协同过滤算法会耗费大量时间和资源来建立模型，而且在预测过程中只使用部分数据进行推荐，这可能会对预测的准确性产生一定的影响。因此本课题选择不采用基于模型的协同过滤算法。

2.2 图表示学习

近年来图表示学习已成为一个广受关注的研究领域。随着图结构数据在社交网络、知识图谱、推荐系统和其他领域的应用日益增多，开发能够处理高维和非线性图数据的模型的需求也更大了。图表示学习的目的是学习到节点或整个图的低维向量表示，同时尽可能保存图中的拓扑结构和各种信息。当两个节点在图中“相邻”时它们在向量空间中的距离会更近，例如当它们的结构相似度很高或它们处于k阶近邻关系中时，它们在向量空间中的距离会更小。这就是图表示学习的关键特征之一。换句话说图表示学习的目标是通过学习节点的向量表示，使得在图中相邻的节点在向量空间中也具有相似的表示。

在图嵌入领域，DeepWalk算法由Perozzi等人^[20]提出。DeepWalk是一种图表示学习算法，旨在将图中的节点转化为低维向量，以便进行深度学习和其他下游任务。该算法的核心思想是通过随机游走生成节点序列，并将节点序列视为词向量。借助Word2Vec^[21]词嵌入方法，DeepWalk学习到节点的低维向量表示：

$$P(v_j|v_i) = \begin{cases} \frac{M_{ij}}{\sum_{j \in N_+(v_i)} M_{ij}} M_{ij}, & v_j \in N_+(v_i) \\ 0, & e_{ij} \notin \varepsilon \end{cases} \quad (2-6)$$

公式(2-6)中， ε 为边集合， $N_+(v_i)$ 为节点 v_i 的出边集合， M_{ij} 表示节点 v_i 到节

点 v_j 的权重。这些节点序列可以用于训练Word2Vec模型，他们类似于自然语言中的句子。DeepWalk算法中的随机游走过程是可控的，可以通过调整参数来控制游走的长度和概率，从而得到不同的节点序列。一旦获得足够数量的节点序列，就可以使用Skip-Gram^[22]模型进行向量学习，将离散的网络节点表示为向量。DeepWalk适用于在线学习节点向量表示，并且能够处理大规模和各种类型的网络^[23]。该算法也存在一些局限性，例如对于一些复杂网络结构可能无法捕捉到更高层次的信息，因此在这些情况下其性能可能会有所下降。

而Grover等人提出了Node2Vec算法。Node2Vec是一种改进的图嵌入算法^[24]，通过调整随机游走的权重，实现在广度优先和深度优先之间的平衡，以达到嵌入在网络同质性和结构性之间的平衡。同质性和结构性分别指距离相近节点的嵌入应尽量接近，以及结构相似节点的嵌入应尽量接近。给定当前顶点 v ，访问下一个顶点 x 的概率为：

$$P(c_i = x | c_{i-1} = v) = \begin{cases} \frac{\pi_{vx}}{Z} & , if (v, x) \in E \\ 0 & , otherwise \end{cases} \quad (2-7)$$

公式(2-7)中， π_{vx} 是顶点 v 和顶点 x 中的未归一化转移概率， Z 是归一化常数。Node2Vec算法引入两个超参数 p 和 q 来控制随机游走的策略，假如当前随机游走经过边 (t, v) 到达顶点 v 设 $\pi_{vx} = \alpha_{pq}(t, x) \cdot \omega_{vx}$ ， ω_{vx} 是顶点 v 和 x 之间的边权：

$$\alpha_{pq}(t, x) = \begin{cases} \frac{1}{p} & if d_{tx} = 0 \\ 1 & if d_{tx} = 1 \\ \frac{1}{q} & if d_{tx} = 2 \end{cases} \quad (2-8)$$

在公式(2-8)中 d_{tx} 为顶点 t 和顶点 x 之间的最短路径距离。通过调整游走策略，如果更偏向广度优先，则能更好地表达网络的同质性信息；如果更偏向深度优先，则能更好地表达网络的整体结构信息。Node2Vec算法已被广泛应用于推荐系统、社交网络分析、生物信息学和图像分析等领域。在推荐系统中，该算法通过深入挖掘用户的历史行为数据，能够学习到用户的嵌入表示，进而增强推荐的精确度。而在社交网络分析领域，Node2Vec算法同样能够学习网络中节点的嵌入表示，从而有助于发现隐藏的社区结构、预测用户行为等高级分析任务。尽管Node2Vec相较于DeepWalk有许多改进之处，但仍存在一些缺陷，例如计算量较大，训练过程需要消耗大量时间和计算资源。

2.3 图神经网络

图神经网络是一种深度学习技术，它在搜索、推荐系统、自然语言处理等重要领域得到了广泛的应用^[25]。作为一种强大的工具，图神经网络能够有效地处理结构化数据，并通过学习节点之间的关系和图的拓扑结构，捕捉到节点之间的相互作用和影响。这使得图神经网络能够实现更准确的数据分析和预测，为各个领域带来了显著的好处和改进。无论是处理社交网络、知识图谱还是其他具有复杂连接关系的非欧几里德结构数据，图神经网络都展现出了其强大的能力和潜力。对于含 n 个定点的无向图 $G = (V, E)$ ，其上未正则化的拉普拉斯矩阵可定义为：

$$L = D - A \quad (2-9)$$

公式(2-9)中， $D = (d_1, \dots, d_n)$ 为图的度矩阵， d_i 表示第 i 个节点的度， A 表示图的邻接矩阵。基于传统傅里叶变换在图上定义卷积：考虑 L 的特征分解 $U\Delta U^T$ ，对一个图信号 f ，其傅里叶变换为 $U^T f$ ，从而对 f 和一个滤波器 h 。图上的卷积运算可定义为：

$$(f * h)_G = U((U^T h) \odot (U^T f)) \quad (2-10)$$

公式(2-10)式中的 \odot 表示哈达码积，将 $U^T h$ 视为可参数化的卷积核，可得到GCN中的卷积公式。为了降低计算的复杂度，该模型通过一阶切比雪夫多项式实现卷积运算的局部一阶近似：

$$H^{(l+1)} = \sigma(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(l)} W^{(l)}) \quad (2-11)$$

公式(2-11)中 \tilde{A} 是无向图 G 添加了自链接之后的邻接矩阵，且 $\tilde{A} = A + I_N$ ； $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$ ； $W^{(l)}$ 是权重矩阵； $\sigma(\cdot)$ 是激活函数， $H^{(l)}$ 是第 l 层上的节点表示。

2.4 图对比学习

图对比学习（Graph Contrastive Learning, GCL）是一种针对图数据的无监督学习方法，其核心在于通过对比学习的方式学习图中节点的表征。相较于依赖人工标注标签的监督学习，自监督学习能够利用数据自身的特性进行自主学习，无需外部标注，从而提高了学习的灵活性和泛化能力。

图对比学习的目标是将相似的节点聚集在一起，将不相似的节点分开。它通过构建正样本对和负样本对，通过最大化正样本对之间的相似性以及最小化负样本对之间的相似性，来学习节点的嵌入表示。对于每个节点而言，通过采

样其邻居节点或其他方式构建正样本对，然后再从其他节点中随机采样构建负样本对。通过比较这些样本对的相似性优化目标函数，图对比学习算法能够推动相似节点在嵌入空间中更加接近，不相似节点则被远离。图对比学习的优势在于能够从无监督的图数据中学习节点的相关表示。这种表示可以应用于各种图相关的任务，如节点分类、链接预测、图聚类等。通过学习到节点的表征表示，图对比学习能够更好地捕捉节点之间的结构和关系，提高图数据的表征能力和任务性能。其通用流程如图2.2所示，原始数据D通过多种数据增强方式 $\Gamma(\cdot)$ （如节点丢弃、边丢弃、随机游走）得到数据增强的结果 \tilde{D} ，再将该结果送到某一个流行的推荐系统模型中。之后将得到的特征结果表示为 $f_{\theta}(\tilde{D})$ ，再将这些特征映射到低维向量空间用来做对比学习任务，即 $g_{\phi_s}(\cdot)$ 。这个过程其实就是通过多层感知机(Multi Layer Perceptron, MLP)的一层，最后将经过数据增强操作的这些特征计算对比学习的损失，其核心思想就是让多个 \tilde{D} 的特征相近，与其他数据的特征远离。该过程用公式表达如下：

$$f_{\theta}^* = \arg \min_{f_{\theta}, g_{\phi_s}} L_{ssl}(g_{\phi_s}(f_{\theta}(\tilde{D}_1)), f_{\theta}(\tilde{D}_2)) \quad (2-12)$$

近年来，图对比学习已经成为图表示学习领域的研究热点，许多图对比学习方法被提出并在实际任务中取得了良好的效果。这些方法对于处理大规模图数据、挖掘复杂图结构以及解决图相关问题具有重要意义。

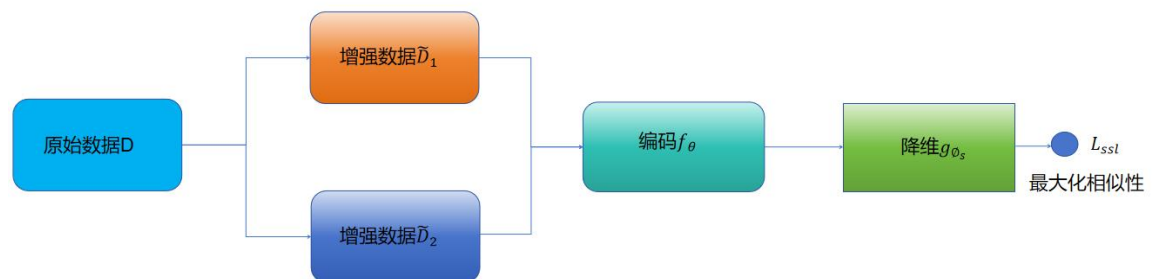


图2.2 对比学习方法基本流程

3. 基于图对比学习的深度推荐方法

本章节在图神经网络和对比学习等相关理论的基础上，设计了基于图对比学习的深度推荐方法（Graph Contrastive Recommendation, GCR）。下面重点阐述此方法的整体设计思路和每一模块的具体设计。

3.1 问题描述

协同推荐系统的核心任务是从用户与项目的交互数据中学习高质量的用户和项目表征。早期的矩阵分解方法^[26]将用户/项目ID简单地映射到嵌入向量，而后续研究^[27]则尝试利用用户行为历史等信息丰富表征学习。近年来，图卷积网络^[28]的引入为表征学习开辟了新的方向，通过利用用户-项目图中的高阶连通性，将多跳邻居信息集成到节点表征中，取得了显著的推荐性能提升。然而，基于图卷积网络的推荐模型仍面临一些挑战。数据稀疏性：监督学习推荐模型^[29]依赖于观察到的用户-项目交互，但这些交互在整个交互空间中非常稀疏，限制了高质量表征的学习；数据倾斜：观察到的交互通常呈现幂律分布，长尾项目缺乏足够的监督信号，而受欢迎的项目则主导了邻域聚合和监督损失，导致模型偏向受欢迎的项目，牺牲了对长尾项目的推荐效果；交互噪声：用户反馈以隐式反馈为主，容易受到噪声影响，例如误导性点击^[30]。图卷积网络的邻域聚合机制放大了噪声的影响，使得表征学习更容易受到干扰。为了构建更强大的协同推荐系统，需要克服这些挑战，开发更有效地利用稀疏数据、处理数据倾斜和抑制交互噪声的模型和方法。

3.2 整体框架

本文主要研究的是基于图对比学习的深度推荐方法。具体的模型框架可分为四个部分（如图3-2）：基于图神经网络的节点表征学习；基于图结构的数据增强，其中在对数据进行增强时使用了节点丢弃；基于增强视图的图对比学习；基于图对比学习的多任务训练。其流程如图3.3所示。具体描述如下：

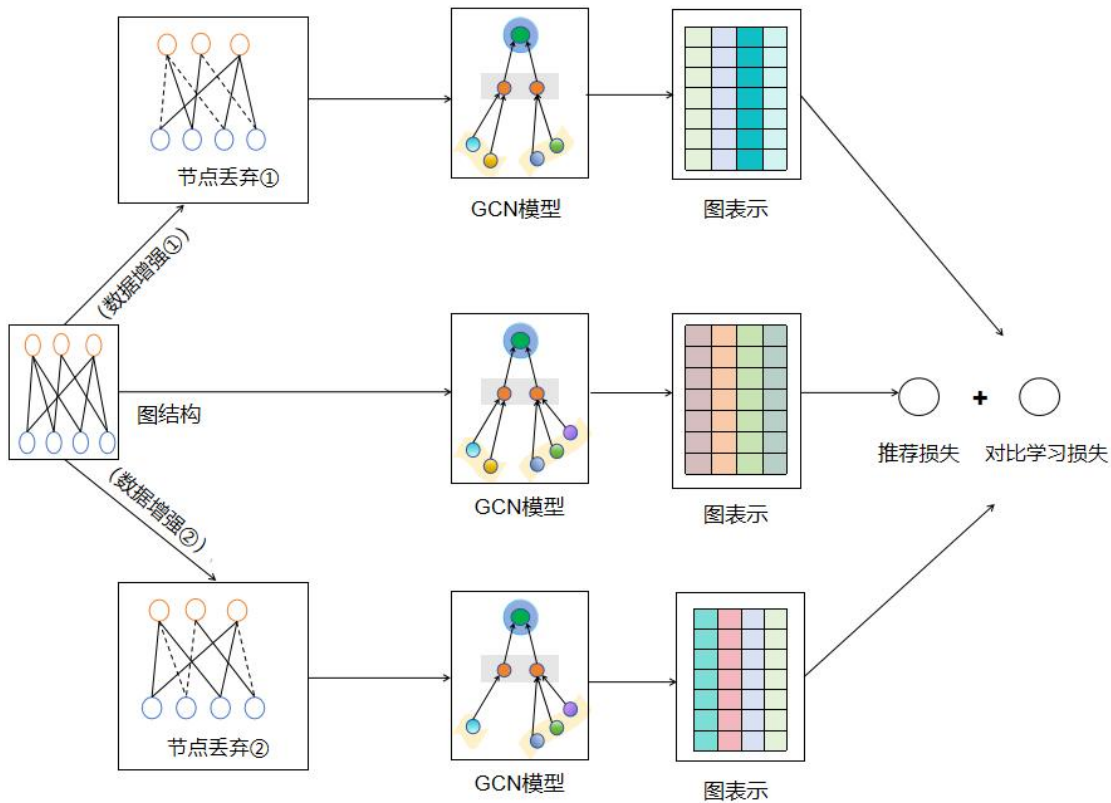


图3.2 图对比学习模型框架

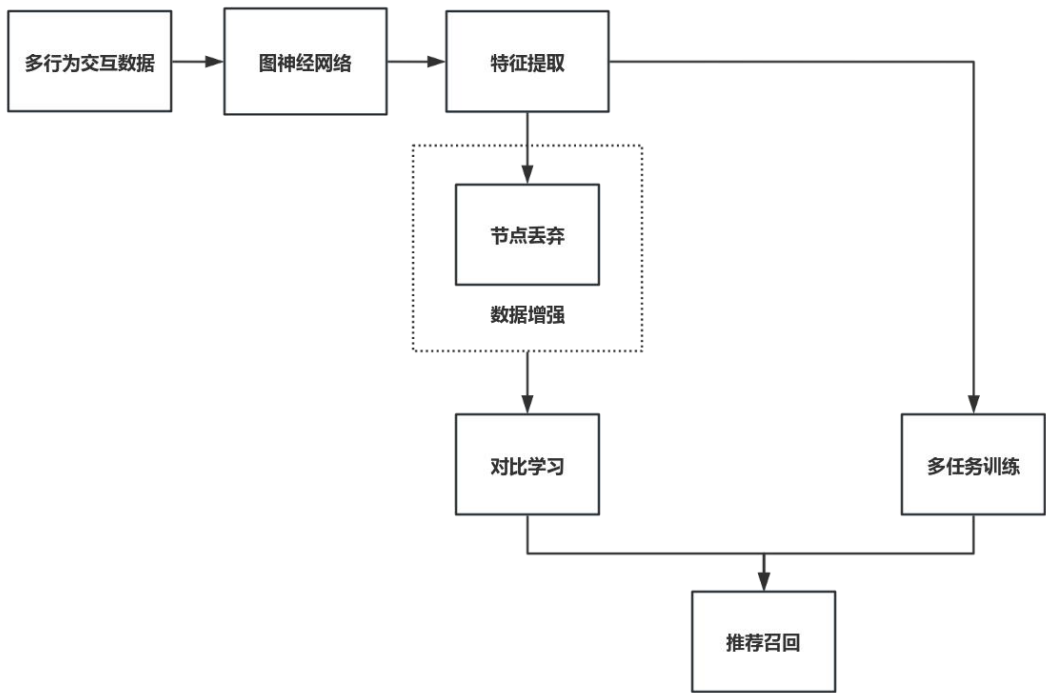


图3.3 图对比学习模型流程

3.2.1 基于图神经网络的节点表征学习

我们首先总结了基于图神经网络的协同过滤推荐模型的常见范例。假设 U 和 I 分别为用户和项目的集合，那么观察到的交互为 $O^+ = \{y_{ui} | u \in U, i \in I\}$ 其中 y_{ui} 表示用户 u 之前与项目 i 交互过。大多数现有模型都是构造一个二分图 $G = (V, E)$ ，其中节点集 $V = U \cup I$ 涉及所有用户和项目，边集 $E = O^+$ 表示观察到的交互。我们回顾图卷积网络，它的核心是将邻域聚合方案应用于 G ，通过聚合邻域节点的表征来更新节点本身的表征：

$$Z^{(l)} = H(Z^{(l-1)}, G) \quad (3-1)$$

在公式(3-1)中 $Z^{(l)}$ 表示第 l 层的节点表征， $Z^{(l-1)}$ 表示前一层的节点表征， $Z^{(0)}$ 表示用户 ID 嵌入 (用户初始嵌入向量)，是可训练参数。 H 表示邻域聚合函数。从向量层的表示为：

$$Z_u^{(l)} = f_{combine}(Z_u^{(l-1)}, f_{aggregate}(\{Z_i^{(l-1)} | i \in N_u\})) \quad (3-2)$$

为了更新节点 u 在第 l 层的表征，它首先聚合其邻居 N_u 在 $(l-1)$ 层的项目表征，然后与用户表征 $Z_u^{(l-1)}$ 结合。这里我们使用加权求和。在获得第 l 层表征后，使用读出函数来生成用于预测的最终表示：

$$Z_u = f_{readout}(\{Z_u^{(l)} | l = [0, \dots, L]\}) \quad (3-3)$$

在最终表示的基础上建立一个预测层，采用内积的方式来预测节点 u 与 i 交互的可能性：

$$\hat{y}_{ui} = Z_u^T Z_i \quad (3-4)$$

为了优化模型参数，现有的研究通常将任务设定为监督学习，其中的监督信号来自观察到的交互（即图 G 中的边）。例如，尽可能使预测值 \hat{y}_{ui} 接近真实值 y_{ui} ，并从从未交互过的项目集中选择负样本。在本文中使用成对贝叶斯个性化排序损失（Bayesian Personalized Ranking Loss），强制要求对观察到的交互进行的预测得分要高于未观察到的交互行为的预测得分：

$$L_{main} = \sum_{(u,i,j) \in O} -\log \sigma(\hat{y}_{ui} - \hat{y}_{uj}) \quad (3-5)$$

在公式(3-5)中， $O = \{(u,i,j) | (u,i) \in O^+, (u,j) \in O^-\}$ 是训练数据， $O^- = U \times I \setminus O^+$ 是未观察到的交互。

3.2.2 基于图结构的数据增强

传统的图像数据增强方法如随机裁剪、旋转或模糊，并不适用于基于图的推荐系统。因为图中的用户和项目特征是离散的，例如one-hot ID等分类变量，无法进行图像处理式的操作。此外，图中用户和项目之间存在相互依赖关系，与计算机视觉(Computer Vision, CV)和自然语言处理(Natural Language Processing, NLP)任务中独立处理数据实例不同^[31]，因此需要针对图结构设计新的数据增强方法。用户与项目之间的二分图映射了用户的行为倾向和偏好，其中包含了丰富的协同过滤信息。在用户-项目交互图中，用户的第一阶邻居即为用户直接交互过的项目，它们构成了用户的历史行为特征；而第二阶邻居则反映了与用户具有相似行为模式的其他用户或项目，这在一定程度上揭示了用户的潜在兴趣所在。基于上述观察，我们可以利用图结构设计数据增强操作，以创建不同的节点视图。

本文方法使用的是节点丢弃的数据增强操作。通过这种数据增强方法，我们可以挖掘图结构中的固有模式，提高推荐系统的泛化能力和鲁棒性。运算符可以统一表示为：

$$Z_1^{(l)} = H(Z_1^{(l-1)}, s_1(G)), Z_2^{(l)} = H(Z_2^{(l-1)}, s_2(G)), s_1, s_2 \sim S \quad (3-6)$$

在公式(3-6)中，在图 G 上独立应用两个随机选择 s_1 和 s_2 ，建立节点 $Z_1^{(l)}$ 和 $Z_2^{(l)}$ 的两个相关视图。

节点丢弃是每个节点连同其连接的边以 p 的概率一起从图中被丢弃。特别地， s_1 和 s_2 可以建模为如式 (3-7)，其中 M' 和 M'' 是两个掩码向量，取值为 0 到 1，作用于节点集合 V ，生成两个子图。因此，这种增强操作旨在从不同的增强视图中识别有影响力的节点，并使表征学习对于结构变化的敏感性降低。

$$s_1(G) = (M' \odot V, E), \quad s_2(G) = (M'' \odot V, E) \quad (3-7)$$

3.2.3 基于增强视图的图对比学习

在建立节点的增强视图后，将同一节点的视图视为正样本对（即， $\{(Z_u', Z_u'') | u \in U\}$ ），将不同节点的视图视为负样本对（即， $\{(Z_u', Z_v'') | u, v \in U, u \neq v\}$ ）。对于正样本对，辅助监督鼓励对同一节点的不同视图进行一致性预测，而对于负样本对，监督则强调不同节点之间的差异性。具体而言就是最大

化正样本对的一致性并最小化负样本对的一致性：

$$L_{ssl}^{user} = \sum_{u \in U} -\log \frac{\exp(s(Z_u', Z_u'')/\tau)}{\sum_{v \in U} \exp(s(Z_u', Z_v'')/\tau)} \quad (3-8)$$

公式(3-8)中 $s(\cdot)$ 是计算两个向量相似度的函数；我们在这里使用余弦相似度函数。 T 是被称为温度的超参数。它用于调整模型对难分节点的区分力度。用同样的方法可以获得项目的对比损失 L_{ssl}^{item} 。将这两个损失结合起来，即可得到自监督任务的目标函数：

$$L_{ssl} = L_{ssl}^{user} + L_{ssl}^{item} \quad (3-9)$$

3.2.4 基于图对比学习的多任务训练

为了改进推荐系统的性能，本文采用了多任务训练策略来联合优化经典推荐任务(式(3-5))和图对比学习任务(式(3-8))。在本文训练任务中，我们使用Adam优化器进行优化。Adam是一种基于梯度下降算法的自适应学习率优化器。它可以根据训练过程中的每个参数的历史梯度和更新情况来自适应地调整每个参数的学习率，从而加速神经网络的训练。

$$L = L_{main} + \lambda_1 L_{ssl} + \lambda_2 ||\theta||_2^2 \quad (3-10)$$

该多任务训练策略如公式(3-10)，其中 L 表示本文方法的总损失函数， L_{main} 是经典推荐任务损失， L_{ssl} 是图对比学习任务损失。 θ 是 L_{main} 中模型参数的集合，由于 L_{ssl} 没有引入额外的参数。因此只有 L_{main} 中的参数需要正则化。 λ_1 、 λ_2 分别是控制图对比学习任务 and L_2 正则化强度的超参数。

3.3 算法描述

本文方法主要分为特征提取、数据增强、图对比学习三个部分。首先从用户项目交互图中获取用户和项目的嵌入向量，这在初始化Initialize部分完成。伪代码第1行至第10行为数据增强部分，通过随机生成掩码向量对图 G 节点丢弃从而得到图 $G1$ 和 $G2$ 。并通过获取邻居节点信息来迭代更新节点信息；伪代码第11至16行是对比由节点丢弃产生的图 $G1$ 和 $G2$ 的信息特征，来计算用户和项目损失，并结合BPR损失计算总损失，最后使用梯度下降法继续优化正样本对和负样本对。伪代码描述如下：

算法3.1 基于图对比学习学习的深度推荐算法

Input: 用户-项目交互图 G , 迭代次数 num_epochs , 隐藏层数量 k , 权重系数 λ , 丢弃率 dropout .

Output: 节点嵌入 Z

Initialize: 图 $G = (U, V, E)$, 随机初始化用户嵌入 U 和项目嵌入 V , E 作为交互的边集。

1. **for** $\text{step} = 1 \dots \text{num_epochs}$ **do**
2. 以丢弃率 drop_rate 随机生成掩码向量 M_1 、 M_2
3. 用掩码向量 M_1 、 M_2 对图 G 随机丢弃节点得到图 G_1 和 G_2 。
5. **for** $l = 1 \dots K$ **do**
6. 用 N' 和 N'' 分别是节点 i 在图 G_1 和 G_2 上的邻居节点集合。
7. $Z^{(l)} \leftarrow f_{\text{combine}}(Z^{(l-1)}, f_{\text{aggregate}}(\{Z_i^{(l-1)} | i \in N\}));$
8. $Z'^{(l)} \leftarrow f_{\text{combine}}(Z'^{(l-1)}, f_{\text{aggregate}}(\{Z_i'^{(l-1)} | i \in N'\}));$
9. $Z''^{(l)} \leftarrow f_{\text{combine}}(Z''^{(l-1)}, f_{\text{aggregate}}(\{Z_i''^{(l-1)} | i \in N''\}));$
10. **end for**
11. 计算 BPR 损失: $L_{\text{main}} \leftarrow \sum_{(u,i,j \in O)} -\log \sigma(\hat{y}_{ui} - \hat{y}_{uj})$;
12. 计算用户损失: $L_{\text{ssl}}^{\text{user}} \leftarrow \sum_{u \in U} -\log \frac{\exp(s(Z'_u, Z''_u)/\tau)}{\sum_{v \in U} \exp(s(Z'_u, Z''_v)/\tau)}$;
13. 计算项目损失: $L_{\text{ssl}}^{\text{item}} \leftarrow \sum_{u \in U} -\log \frac{\exp(s(Z'_u, Z''_u)/\tau)}{\sum_{v \in U} \exp(s(Z'_u, Z''_v)/\tau)}$;
- $$L_{\text{ssl}} = L_{\text{ssl}}^{\text{user}} + L_{\text{ssl}}^{\text{item}}$$
14. $L \leftarrow L_{\text{main}} + \lambda_1 L_{\text{ssl}} + \lambda_2 ||\theta||_2^2$;
15. 使用梯度下降法继续优化 Z_u 和 Z_i
16. **end for**
17. **return** Z ;

4. 实验与分析

本章使用了ml-1M、douban-book、Yelp2018三个数据集，通过与LightGCN进行结果对比来评估本文提出的推荐算法的有效性。通过改进网络层数L、权重系数 λ 、丢弃率dropout、温度参数temp四个参数来进行本文方法的超参数实验。

4.1 实验环境

(1) 硬件环境

CPU: Intel(R) Core(TM) i5-10300H CPU @ 2.50GHz 2.50 GHz

显卡: NVIDIA GeForce GTX 1650 Ti

内存: 16.0 GB

(2) 软件环境

操作系统: 64位windows10

编程语言: python

集成开发环境: PyCharm

4.2 数据集

本文使用的数据集为ml-1M、douban-book、Yelp-2018。其中ml-1M包含一百万个电影评分数据，6000多个用户对4000多部电影的评分；图书评分数据集douban-book，包含了用户对豆瓣图书的评分数据；商家评价数据集Yelp-2018，包含了用户对商家的评价和评论数据，以及商家的相关信息。本文研究内容用到的部分数据集如下：

表4.1 数据集描述

Dataset	Users	Items	Scale	Density
ml-1M	6036	2445	[1,5]	0.9581%
douban	2,848	39,586	[1,5]	0.794%
Yelp-2018	19,539	21,266	implicit	0.11%

4.3 评估指标介绍

1) Hit Ratio (命中率)

命中率强调预测的“准确性”，在公式(4-1)中N表示用户的访问量，即点击数。hit(i)表示系统是否推荐项目i，是则hit(i)的值为1，否则为0。

$$HR = \frac{1}{N} \sum_{i=0}^N \text{hit}(i) \quad (4-1)$$

2)NDCG(Normalized Discounted Cumulative Gain,归一化折损累计增益)

归一化折损累计增益强调项目放置的位置是否显眼，用户能否更好的找到，在公式(4-2)中，N表示用户的访问总量， p_i 表示项目i在推荐结果中出现的位置。

$$NDCG = \frac{1}{N} \sum_{i=1}^N \frac{1}{\log_2 (p_i+1)} \quad (4-2)$$

3)Recall（召回率）

召回率是衡量模型性能的重要指标，其指的是模型正确识别出的正类样本占有所有实际正类样本的比例。在公式(4-3)中，TP（True Positives）是被正确分类为正样本的样本数量。FN（False Negatives）是被错误分类为负类的实际正类样本数量。

$$\text{Recall} = \frac{TP}{TP+FN} \quad (4-3)$$

4.4 实验参数设置

我们将学习率设置为0.001，epochs设置为50，batch_size设置为512，droptout设置为0.1，输入的特征向量维度为16，得到的拼接向量维度为64。Adam优化器的学习率设置为0.001。

4.5 准确性分析

我们在表4.2和表4.3中展示了LightGCN和本文方法（GCR）两种推荐方法的结果，得出了以下结论：1)本文方法推荐效果更佳。在douban-book数据集上的Recall@20提升高达16%，NDCG@20提升高达19.7%。几乎在大多数情况下本文方法的表现都明显优于LightGCN，这证明了方法的有效性。2)与Yelp-2018上的表现相比，方法在douban-book上的表现有明显提升。Yelp-2018相较于其他两个数据集数据量大，拥有更丰富的交互和联系，而另外两个数据集所包含的信息量较少，没有足够数据供模型学习隐藏关联，而表现相反，这说明在解决数据稀缺性问题上有很大作用。

表4.2 LightGCN和GCR的Recall@20和NDCG@20指标对比

数据集	评估指标	LightGCN	GCR
Yelp-2018	Recall@20	0.06310	0.06430
	NDCG@20	0.05150	0.05290
ml-1M	Recall@20	0.27230	0.27558
	NDCG@20	0.30337	0.31032
douban-book	Recall@20	0.15067	0.17480
	NDCG@20	0.12737	0.15256

表4.3 LightGCN和GCR的Recall@40和NDCG@40指标对比

数据集	评估指标	LightGCN	GCR
Yelp-2018	Recall@40	0.08130	0.08926
	NDCG@40	0.64230	0.07122
ml-1M	Recall@40	0.39278	0.39600
	NDCG@40	0.33027	0.33699
douban-book	Recall@40	0.21550	0.24251
	NDCG@40	0.14602	0.17228

4.6 超参数分析

本节是对本文模型的超参数实验：在保证其它参数不变时，分别改变网络层数 L 、权重系数 λ 、丢弃率 dropout 、温度参数 temp 来观察Hit Ratio、NDCG、Recall、Precision四个评估指标的变化以找出最佳参数。本实验均使用了ml-1M和douban-book两个数据集。

4.6.1 不同网络层数的影响

本小节对比了本文模型和LightGCN在不同迭代次数时的Hit Ratio和Recall两个指标，我们将网络层数 Layer 设置为 $\{1,2,3,4,5,6\}$ ，以挖掘多层次对结果的影响，选取ml-1M和douban-book两个数据集来对比观察，如图4.1和4.2所示。

由实验结果可以看出：（1）本文方法的命中率和召回率在两个数据集中均明显高于LightGCN。这体现出本文方法明显优于LightGCN，同时也表明了本文

方法在一定程度上解决了原有的数据稀缺、噪声等问题，提升了推荐系统的鲁棒性，使推荐结果更准确。（2）本文方法在ml-1M数据集下在Layer=2时推荐表现最佳，douban-book数据集下在Layer=3时推荐表现更优，而在层数更大或更小时表现优劣不一，由此可以看出这两种方法的迭代层数应适中，应分别选取Layer=2,3为最佳参数。

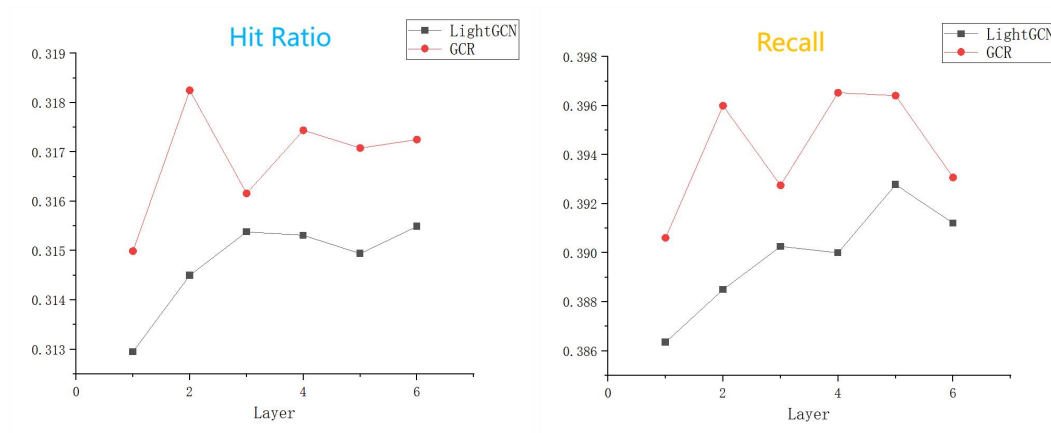


图4.1 ml-1M数据集下GCR和LightGCN在不同网络层数时的命中率和召回率的比较




图4.2 douban-book数据集下GCR和LightGCN在不同网络层数时的命中率和召回率的比较

4.6.2 不同温度参数的影响

我们在不改变权重系数 λ 、丢弃率dropout、网络层数Layer的情况下设置温度参数temp为{0.1,0.2,0.3,0.4,0.5}，在ml-1M和douban-book两个数据集上比较本文模型在评估指标Hit Ratio、NDCG、Recall、Precision的变化，如表4.2和表4.3所示。

由表4.2、4.3可以看出，当temp刚开始增大时，系统各项指标也逐渐增大，在temp达到0.2之后，系统性能随temp增大而呈下降势，两个数据集均是如此。

由此可得，当temp=0.2时系统推荐性能最佳，这是因为温度参数控制着模型的随机性和创造性，所以为了模型既不能太“保守”也不能太“冒险”，温度参数应该取最优值，即temp=0.2。

表4.2 ml-1M数据集下改变温度参数对GCR方法的影响

Temp	0.1	0.2	0.3	0.4	0.5
Hit Ratio	0.20299	0.20977	0.20876	0.20873	0.20798
Precision	0.19471	0.20121	0.20024	0.20021	0.19949
Recall	0.26411	0.27558	0.2751	0.27566	0.27255
NDCG	0.3006	0.31032	0.30822	0.30714	0.30613

表4.3 douban-book数据集下改变温度参数对GCR方法的影响

Temp	0.1	0.2	0.3	0.4	0.5
Hit Ratio	0.11684	0.12951	0.12705	0.12468	0.12351
Precision	0.06538	0.07248	0.0711	0.06977	0.06912
Recall	0.15957	0.1748	0.1712	0.16801	0.16604
NDCG	0.13675	0.15256	0.15052	0.14709	0.14482

4.6.3 不同丢弃率的影响

我们在不改变权重系数 λ 、温度参数temp、网络层数Layer的情况下设置丢弃率dropout为{0.1,0.2,0.3,0.4,0.5}，在ml-1M和douban-book两个数据集上比较本文模型在评估指标Hit Ratio、NDCG、Recall、Precision的变化，如表4.4和表4.5所示。由表4.4、表4.5可以看出，在ml-1M数据集中，当dropout值为0.2时，各项指标均达到了最大值，而在douban-book数据集中最佳dropout值为0.3。在两个数据集中dropout参数的最佳值不一致，这缘于douban-book相比ml-1M其项目数量更多，项目种类更丰富特征更众多，此时就需要适当增大丢弃率使推荐效果更佳。

表4. 4 ml-1M数据集下改变丢弃率对GCR方法的影响

Dropout	0.1	0.2	0.3	0.4	0.5
Hit Ratio	0.20881	0.20977	0.20873	0.20873	0.21008
Precision	0.20029	0.20121	0.20022	0.20022	0.20151
Recall	0.27399	0.27558	0.27407	0.27431	0.27527
NDCG	0.30749	0.31032	0.30991	0.30909	0.31017

表4. 5 douban-book数据集下改变丢弃率对GCR方法的影响

Dropout	0.1	0.2	0.3	0.4	0.5
Hit Ratio	0.12809	0.12872	0.12951	0.12965	0.12983
Precision	0.07168	0.07203	0.07248	0.07255	0.07265
Recall	0.17332	0.17381	0.1748	0.17472	0.17418
NDCG	0.15187	0.1517	0.15256	0.15254	0.15191

4. 6. 4 不同λ权重系数的影响

我们在不改变温度参数temp、丢弃率dropout、网络层数Layer的情况下改变权重系数λ为{0.1,0.2,0.3,0.4,0.5}，在ml-1M和douban-book两个数据集上比较本文模型在评估指标Hit Ratio、NDCG、Recall、Precision的变化，如图4.3和图4.4所示。

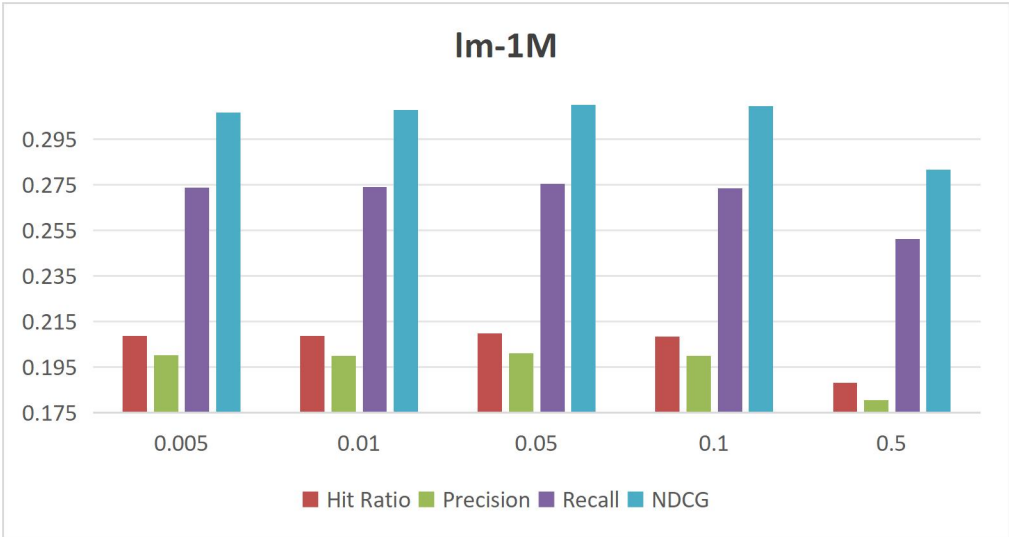


图4. 3 ml-1M数据集下改变 λ 对GCR方法的影响




图4.4 douban-book数据集下改变 λ 对GCR方法的影响

由以上两柱形图可看出，随着 λ 的不断增大，各项评估指标呈先升后降的趋势，在数据集douban-book上变化更为明显。在本实验中， λ 是图对比学习任务的损失权重，当 λ 持续增大时，图对比学习任务损失比重在总损失中变大，而经典推荐任务损失比重减小。我们发现当 $\lambda=0.05$ 时系统的各项评估指标达到最优值，推荐效果最好，所以图对比学习任务的损失权重不易过大或过小应取最优值。

结论

本次毕业设计聚焦于基于图对比学习的深度推荐方法,提出了将图神经网络与图对比学习相融合,通过数据增强操作去破坏用户-项目二分图,再从这些被破坏的图中进行对比学习,通过最大化同一节点在不同视图下的表征的相似性,同时最小化不同节点表征之间的相似性,来优化模型的学习目标。再通过与LightGCN模型进行比对从而观察系统的推荐效果的提升程度,一定程度上解决了基于二分图表征学习的推荐系统面临的噪声问题。主要工作内容如下:

- (1) 利用Pytorch搭建了实验环境。
- (2) 搜寻了合适的数据集(ml-1M、Yelp-2018、douban-book),并对数据进行了加载和划分等操作。
- (3) 从数据集中获取用户和项目的嵌入向量表征,再对其二分图进行数据增强操作(节点丢弃)从而提高模型对于噪声交互的鲁棒性。
- (4) 对于数据增强操作后生成的多种子视图中的多种表征,借鉴对比学习的思路,构造图对比学习任务。
- (5) 与LightGCN进行结果比对验证其有效性,并探究模型中各参数对预测性能的影响。

毕业设计的工作可能暂时落下帷幕,但学习的路程还在继续。就本课题而言,仍存在许多可以改进的问题,例如除LightGCN外,本文方法与别的经典推荐模型相比性能如何、如何进一步提高算法推荐的准确性等。课题仍存在完善和进步的空间,相信这些问题会在以后的学习过程中被一一解决。

致谢

转眼间四年时间已经过去了，第一次踏入南理工的画面仿佛就在眼前。越是在离别之际，那些不曾被发现的简单和美好会一一乍现在脑海。在做毕业设计的这段日子里，生活忙而充实，每当疲惫的时候走在正值五月春色的南理工，那种心旷神怡的感觉不禁让我自豪我在这里度过了人生中美好的四年。

特别感谢我的导师孟顺梅老师对我论文的悉心指导。在毕业设计和完成论文的过程中，老师除了一直在关心和督促我以外，还给予了很多鼓励，这让基础本不是太好的我也有信心完成这项挑战。并且在我遇到很小很基础的问题时也非常耐心的跟我解答。我非常高兴选择孟顺梅老师做我的毕设导师，感谢您。

也感谢我的父母以及陪我度过这四年的所有朋友，谢谢你们！

参考文献

- [1] 于蒙, 何文涛, 周绪川, 等. 推荐系统综述[J]. 计算机应用, 2022, 42(6): 1898.
- [2] 赵俊逸, 庄福振, 敖翔, 等. 协同过滤推荐系统综述[J]. Journal of Cyber Security 信息安全学报, 2021, 6(5).
- [3] Bao K, Zhang J, Zhang Y, et al. Tallrec: An effective and efficient tuning framework to align large language model with recommendation[C]//Proceedings of the 17th ACM Conference on Recommender Systems. 2023: 1007-1014.
- [4] Yang Y, Huang C, Xia L, et al. Debiased contrastive learning for sequential recommendation[C]//Proceedings of the ACM web conference 2023. 2023: 1063-1073.
- [5] Belkin N J, Croft W B. Information filtering and information retrieval: Two sides of the same coin?[J]. Communications of the ACM, 1992, 35(12): 29-38.
- [6] Goldberg D, Nichols D, Oki B M, et al. Using collaborative filtering to weave an information tapestry[J]. Communications of the ACM, 1992, 35(12): 61-70.
- [7] Resnick P, Iacovou N, Suchak M, et al. Grouplens: An open architecture for collaborative filtering of netnews[C]//Proceedings of the 1994 ACM conference on Computer supported cooperative work. 1994: 175-186.
- [8] Resnick P, Varian H R. Recommender systems[J]. Communications of the ACM, 1997, 40(3): 56-58.
- [9] Linden G, Smith B, York J. Amazon. com recommendations: Item-to-item collaborative filtering[J]. IEEE Internet computing, 2003, 7(1): 76-80.
- [10] Scarselli F, Gori M, Tsoi A C, et al. The graph neural network model[J]. IEEE transactions on neural networks, 2008, 20(1): 61-80.
- [11] Wang W, Feng F, He X, et al. Clicks can be cheating: Counterfactual recommendation for mitigating clickbait issue[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2021: 1288-1297.
- [12] Li H, Zheng C, Zhou X H, et al. Stabilized doubly robust learning for recommendation on data missing not at random[J]. arXiv preprint arXiv:2205.04701, 2022.

- [13] Chen J, Feng Y, Ester M, et al. Modeling users' exposure with social knowledge influence and consumption influence for recommendation[C]//Proceedings of the 27th ACM International Conference on Information and Knowledge Management. 2018: 953-962.
- [14] Liang D, Charlin L, McInerney J, et al. Modeling user exposure in recommendation[C]//Proceedings of the 25th international conference on World Wide Web. 2016: 951-961.
- [15] Zhang J, Shi X, Xie J, et al. Gaan: Gated attention networks for learning on large and spatiotemporal graphs[J]. arXiv preprint arXiv:1803.07294, 2018.
- [16] Roposch A, Graf R, Wright J G. Determining the reliability of the Graf classification for hip dysplasia[J]. Clinical Orthopaedics and Related Research®, 2006, 447: 119-124.
- [17] Abu-El-Haija S, Perozzi B, Kapoor A, et al. Mixhop: Higher-order graph convolutional architectures via sparsified neighborhood mixing[C]//international conference on machine learning. PMLR, 2019: 21-29.
- [18] Wang X, Ji H, Shi C, et al. Heterogeneous graph attention network[C]//The world wide web conference. 2019: 2022-2032.
- [19] 王健宗, 孔令炜, 黄章成, 等. 图神经网络综述[J]. 计算机工程, 2021, 47(4): 1-12.
- [20] Perozzi B, Al-Rfou R, Skiena S. Deepwalk: Online learning of social representations[C]//Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining. 2014: 701-710.
- [21] Di Gennaro G, Buonanno A, Palmieri F A N. Considerations about learning Word2Vec[J]. The Journal of Supercomputing, 2021: 1-16.
- [22] Song Y, Shi S, Li J, et al. Directional skip-gram: Explicitly distinguishing left and right context for word embeddings[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers). 2018: 175-180.
- [23] 徐冰冰, 岑科廷, 黄俊杰, 等. 图卷积神经网络综述[J]. 计算机学报, 2020, 43(5): 755-780.
- [24] Grover A, Leskovec J. node2vec: Scalable feature learning for networks[C]//Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining. 2016: 855-864.

- [25] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.
- [26] Rendle S, Freudenthaler C, Gantner Z, et al. BPR: Bayesian personalized ranking from implicit feedback[J]. arXiv preprint arXiv:1205.2618, 2012.
- [27] Koren Y. Factorization meets the neighborhood: a multifaceted collaborative filtering model[C]//Proceedings of the 14th ACM SIGKDD international conference on Knowledge discovery and data mining. 2008: 426–434.
- [28] He X, Deng K, Wang X, et al. Lightgcn: Simplifying and powering graph convolution network for recommendation[C]//Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. 2020: 639–648.
- [29] He X, Liao L, Zhang H, et al. Neural collaborative filtering[C]//Proceedings of the 26th international conference on world wide web. 2017: 173–182.
- [30] Wang W, Feng F, He X, et al. Denoising implicit feedback for recommendation[C]//Proceedings of the 14th ACM international conference on web search and data mining. 2021: 373–381.
- [31] Chen T, Kornblith S, Norouzi M, et al. A simple framework for contrastive learning of visual representations[C]//International conference on machine learning. PMLR, 2020: 1597–1607.
- [32] Qiu J, Chen Q, Dong Y, et al. Gcc: Graph contrastive coding for graph neural network pre-training[C]//Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining. 2020: 1150–1160.